Entropia rynkowa 2007-2012

Jerzy Zeller

February 2026

1 Wstęp

Celem projektu jest próba zbadania zachowania największych amerykańskich giełd poprzez badanie entropii układu(w raporcie taki układ nazywam rynkiem) złożonego ze zmiany cen odpowiadającym im etf-ów, czyli instrumentów finansowych, których wartość ma odzwierciedla wartość ogółu spółek na giełdzie, które reprezentują.

W projekcie badałem SPY odpowiadający S&P 500 , QQQ odpowiadający NASDAQ, VTI odpowiadający Vanguard Total Stock Market, IWM dla iShares Russell 2000 oraz TLT dla iShares 20+ Year Treasury Bond.

Metody i definicje, z których korzystam, wziąłem z artykułu autorstwa Anirban Chakraborti, Hrishidev, Kiran Sharma and Hirdesh K. Pharasi, wdzięcznie zatytułowanym "Phase separation and scaling in correlation structures of financial markets".

2 Model Teoretyczny

2.1 Entropia Rynku

Niech rynek oznacza zbiór akcji, każda z nich ma określoną cenę $pr(t)$ w danej chwili t. Wprowadźmy wielkość odpowiadającą zmianie ceny daną wzorem $r(t) = log(pr(t)) - log(pr(t - \Delta))$.

Teraz możemy rozważyć korelacje między zmianami cen:

$$C_{ij} = \frac{< r_i r_j > - < r_i >< r_j >}{\sigma_i \sigma_j} \tag{1}$$

gdzie uśredniamy po czasie m dla wybranego Δ. (Do obliczeń przyjąłem $m = 30$dni oraz $\Delta = 15$dni)

Zauważmy, że równanie 2.1 zadaje nam wagę połączenia (krawędzie) między dowolnymi dwiema akcjami (wierzchołkami) w każdym momencie τ. Czyli teraz możemy patrzeć na rynek jako na ważony graf, którego wagi zmieniają się w czasie.

Na grafie można wprowadzać pojęcie centralności wierzchołka, mówiące o tym jak bardzo połączony jest dany wierzchołek z pozostałymi mniej lub bardziej centralnymi wierzchołkami.

Centralność p_i wierzchołka i jest zadana wzorem (przyjmujemy że $p_i > 0$):

$$p_i := 1/\lambda \sum_{j \in ssiedzi(i)} p_j (C_{ij})^2 = 1/\lambda \sum_{j \in rynek} p_j (C_{ij})^2 \tag{2}$$

gdzie sumę po sąsiadujących wierzchołkach można zastąpić sumą po wszystkich wierzchołkach, bo 2.1 zadaje krawędź między dowolnymi dwoma wierzchołkami, λ to stała normująca, a podniesienie każdego C_{ij} do kwadratu (w bazie kanonicznej) zapewnia dodatniość każdego p_i.

Zauważmy, że żeby znaleźć centralność wierzchołków wystarczy rozwiązać zagadnienie własne. Z twierdzenia Perrona-Forbeniusa [2] [1] , że największa wartość własna da nam jednowymiarową przestrzeń

odpowiadającą takim p_i, które spełniają definicje. Zauważmy, że jeśli wybierzemy unormowane p_i, na rynek możemy spojrzeć jako na zespół statystyczny, który każdej akcji i przyporządkowuje p_i, ponieważ z konstrukcji zawsze mamy $\sum_i p_i = 1$ oraz $p_i > 0$.

Zauważmy, że dla rozkładu $p_i = \delta_{i1}$, rynek da się opisać znając tylko stan akcji 1 (Układ maksymalnie uporządkowany), a dla sytuacji $p_i = 1/d$, gdzie d to liczba akcji na danym rynku, stan każdej akcji jest równie potrzebny do opisu rynku (układ maksymalnie chaotyczny). Naturalnym jest więc wprowadzenie entropii rynku jako klasycznej entropii informacyjnej Shanona:

$$H(rynku) = -\sum_i p_i log_2 p_i \tag{3}$$

2.2 Dynamika korelacji

Macierz korelacji zdefiniowana wzorem 2.1 ewoluuje razem z parametrem czasowym τ. Korzystając z rozkładu spektralnego możemy rozważyć $C = C_M + C_{GR}$ gdzie $C_M = \lambda_1 |e_1\rangle \langle e_1|$, a $C_{GR} = \sum_i \lambda_i |e_i\rangle \langle e_i|$ ($\lambda_i |e_i\rangle$ to odpowiednio wartość własna i wektor własny, zakładamy brak degeneracji). C_M interpretujemy jako dominujący wkład w dynamikę rynku, odpowiadający realnym wydarzeniom, a C_{GR} jako szum. Zauważmy, że C_M oraz C_{GR} zadają zgodnie ze schematem z poprzedniej podsekcji własne entropie 2.1. Będę je oznaczał odpowiednio H_M oraz H_{GR}.

3 Obliczenia

Poniżej zamieszczam "oczyszczoną"listę poleceń, które wpisałem, z komentarzami wyjaśniającymi tok rozumowania.

```
######Importowanie bibliotek oraz danych
> library(quantmod)
> getSymbols('SPY')
> t1 <- SPY['/2012']
> df1 <-as.data.frame(t1)
> spy1<-df1$SPY.Close
> rspy <- c(rep(NA, 15), diff(spy1, lag = 15))
> rspy<-rspy[16:1510] #analogicznie dla pozostalych etfow


######Konstrukcja stan w macierzy korelacji w czasie
> contdf<-as.data.frame(cbind(rspy,rqqq,rvti,riwm,rtlt))
> colnames(contdf)<-c('spy','qqq','vti','iwm','tlt')
> dfs <- split(contdf, rep(seq_len(nrow(contdf) / 30), each = 30))
> cortau<-lapply(dfs, cor)

######Liczenie centralno ci macierzy korelacji
> A <- lapply(cortau, \(x) x^2)
> p1 <- lapply(seq_along(A), function(i) eigen(A[[i]])$vectors[,1])
> p2 <- lapply(p1, function(x) x*(1/norm(x,type = "2")))
> cent <- lapply(p1, function(x) -x*(1/norm(x,type = "2")))

###### Liczenie C_M oraz jej centralno ci w czasie
> cm1 <- lapply(seq_along(cortau), function(j) eigen(cortau[[j]])$vectors[,1])
> cm15 <- lapply(seq_along(cm1), function(i) -1/norm(cm1[[i]],type = "2") *
    cm1[[i]])
> cm2 <- lapply(seq_along(cm15), function(j) cm15[[j]] %*% t(cm15[[j]]))
> lambda_max = c()
> for(i in 1:length(cortau)){
+       a1<-eigen(cortau[[i]],only.values = TRUE)
+       lambda_max <- append(lambda_max, max(a1[[1]]))
+      }
> cm <- lapply(seq_along(cm2) , function(y) cm2[[y]]*lambda_max[[y]])
```

```
> Am <- lapply(cm, \(x) x^2)
> p1m <- lapply(seq_along(Am), function(i) eigen(Am[[i]])$vectors[,1])
> p2m <- lapply(p1m, function(x) x*(1/norm(x,type = "2")))
> centm <- lapply(p1m, function(x) -x*(1/norm(x,type = "2")))



###### Liczenie C_GR oraz jej centralno ci w czasie

> cgr31 <- lapply(seq_along(cortau), function(j) eigen(cortau[[j]])$vectors[,3])
> cgr315 <- lapply(seq_along(cgr31), function(i) -1/norm(cgr31[[i]],type = "2")
    * cgr31[[i]])
> cgr32 <- lapply(seq_along(cgr315), function(j) cgr315[[j]] %*% t(cgr315[[j]]))
> lambda_max3 = c()
> for(i in 1:length(cortau)){
+     a1<-eigen(cortau[[i]],only.values = TRUE)
+     lambda_max3 <- append(lambda_max3, a1[[1]][3])
+     }
> cgr3 <- lapply(seq_along(cgr32) , function(y) cgr32[[y]]*lambda_max3[[y]])
#tak samo dla wektorow wlasnyh 2,3,4,5
> cgr<-lapply(seq_along(cgr2), function(i) cgr2[[i]] + cgr3[[i]] + cgr4[[i]] +
    cgr5[[i]]
> Agr <- lapply(cgr, \(x) x^2)
> p1gr <- lapply(seq_along(Agr), function(i) eigen(Agr[[i]])$vectors[,1])
> p2gr <- lapply(p1gr, function(x) x*(1/norm(x,type = "2")))
> centgr <- lapply(p1gr, function(x) -x*(1/norm(x,type = "2")))


#####obliczanie entropi
> h <- function(x) {
+     x <- x[x > 0]
+     -sum(x * log2(x))
+ }
> H <- lapply(seq_along(cent), function(i) h(cent[[i]]) )
> Hm <- lapply(seq_along(centm), function(i) h(centm[[i]]) )
> Hgr <- lapply(seq_along(centgr), function(i) h(centgr[[i]]) )

######Rysowanie

#Entropia w czasie
> Ht.df <- as.data.frame(cbind(H,c(1:49)))
> colnames(Ht.df) <- c('H', 'tau')
> Ht.df$H <- unlist(Ht.df$H)
> Ht.df$tau <- unlist(Ht.df$tau)
> ggplot(Ht.df , aes(x= tau, y= H)) + geom_point()

> Hmt.df <- as.data.frame(cbind(Hm,c(1:49)))
> colnames(Hmt.df) <- c('Hm', 'tau')
> Hmt.df$Hm <- unlist(Hmt.df$H)
> Hmt.df$tau <- unlist(Hmt.df$tau)
> ggplot(Hmt.df , aes(x= tau, y= Hm)) + geom_point()

> Hmt.df <- as.data.frame(cbind(Hm,c(1:49)))
> colnames(Hmt.df) <- c('Hm', 'tau')
> Hmt.df$Hm <- unlist(Hmt.df$H)
> Hmt.df$tau <- unlist(Hmt.df$tau)
> ggplot(Hmt.df , aes(x= tau, y= Hm)) + geom_point()


#przekszta cone wsp  rz dne
> deltam <- lapply(seq_along(H), function(i) H[[i]] - Hm[[i]])
```

```
> deltagr <- lapply(seq_along(H), function(i) H[[i]] - Hgr[[i]])
> phspc.df <- as.data.frame(cbind(deltam,deltagr))
> phspc.df$M <- unlist(phspc.df$M)
> phspc.df$R <- unlist(phspc.df$R)


> ggplot(phspc.df, aes(x=M, y=R, color = seq_along(M))) +
+     geom_point() +scale_color_gradientn(
+         colors = c(
+             "#2E0854",
+             "#5E2B97",
+             "#8A2BE2",
+             "#C71585",
+             "#FF4500",
+             "#8B0000"
+         )
+     )+ scale_x_log10() + scale_y_log10()


> ggplot(phspc.df, aes(x = M, y = R, color = seq_along(M))) +
+     geom_point() +
+     scale_color_gradient(low = "blue", high = "red") +
+     theme_minimal()

> Hr <- as.data.frame(cbind(phspc.df$R, c(1:49)))
> colnames(Hr)<-c('Hr','tau')
> ggplot(Hr.df, aes(x=tau,y=hr)) + geom_point()

> Hm.df <- as.data.frame(cbind(phspc.df$M, c(1:49)))
> colnames(Hm.df)<-c('hm','tau')
> ggplot(Hm.df, aes(x=tau,y=hm)) + geom_point()
```

4 Wyniki i interpretacja

Na rysunkach 1, 2 oraz 3 przedstawiono entropie w czasie (przypomnienie: jednostką τ jest jeden miesiąc).

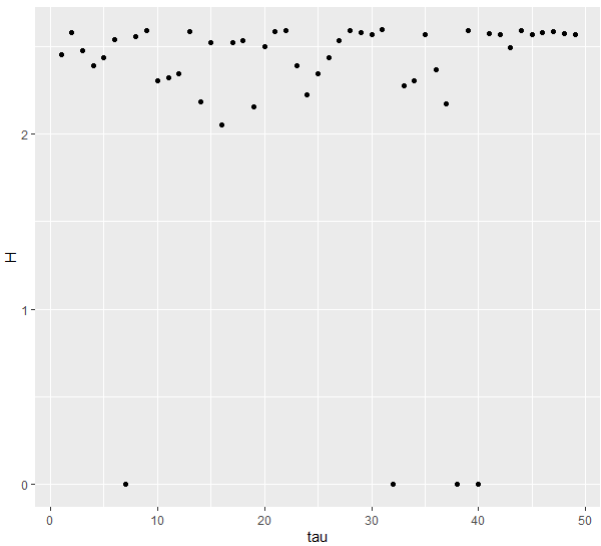

Rysunek 1: Zależność entropii H w czasie

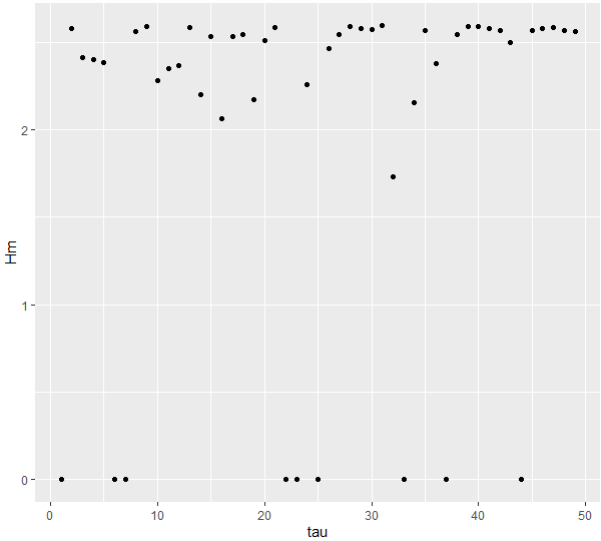

Rysunek 2: Zależność entropii H_M w czasie

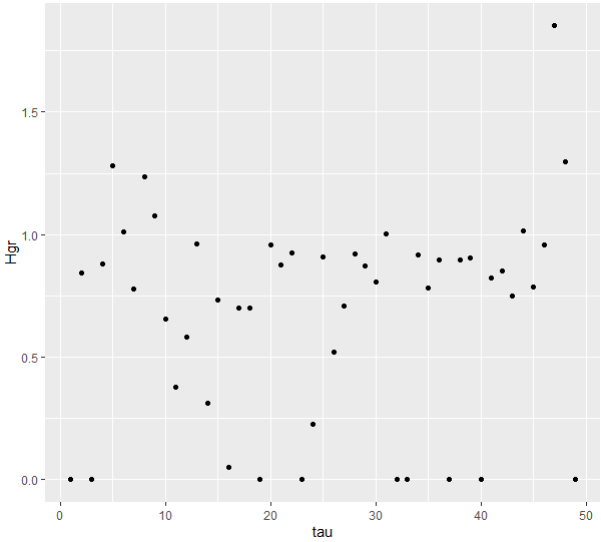

Rysunek 3: Zależność entropii H_{GR} w czasie

Widać, że faktycznie zachowanie entropi dominującego wkładu do dynamiki$C$ zachowuje się prawie dokładnie tak samo jak entropia całego rozpatrywanego rynku. Utrzymuje się w okolicach 2.4 czyli maksymalnej entropi Shanona dla pięciu mikrostanów układu, co oznacza, że giełdy odpowiadające rozpatrywanym etf-om zachowywały się raczej w sposób niepowiązany. Wykracznaie punktów ponad tę wartość jest prawdopodobnie błędami wynikającymi z numerycznego charakteru obliczeń

Na rysunkach 4 oraz 5 przedstawiono próby konstrukcji przestrzeni fazowej tak jak w artykule [2].

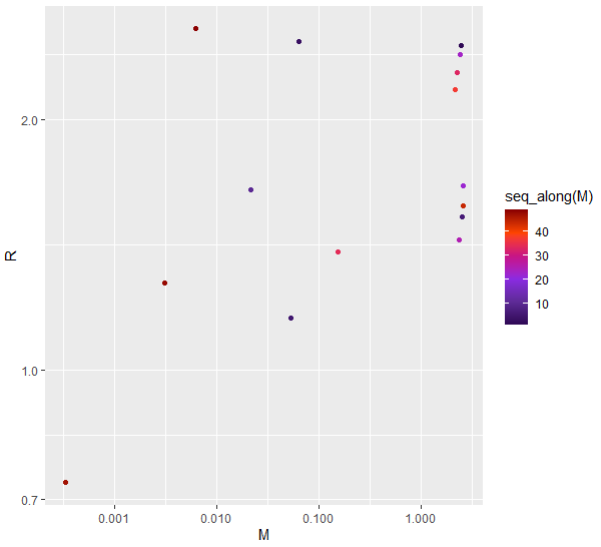

Rysunek 4: Próba rekonstrukcji przestrzeni $R := H - H_{GR}$, $M := H - H_M$ na skali logarytmicznej

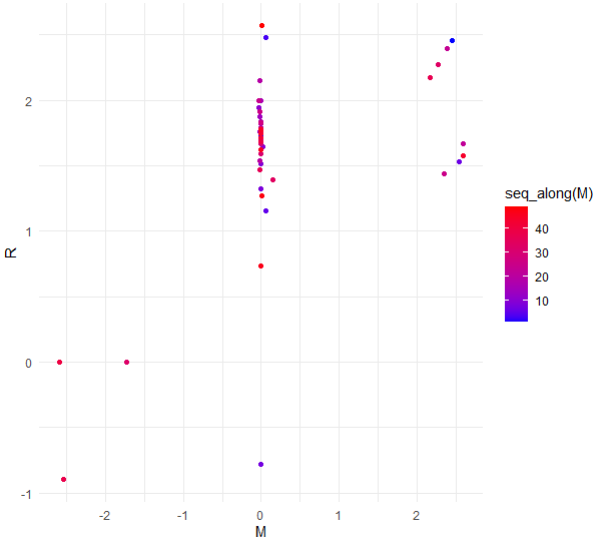

Rysunek 5: Próba rekonstrukcji przestrzeni $R := H - H_{GR}$, $M := H - H_M$

Można zauważyć, że im późniejszy punkt (dalszy od szczytu kryzysu 2008) tym bardziej prawdopodbne że znajdzie się w obszarze $R \approx 1.6$.

5 Podsumowanie

Chociaż udało się wyznaczyć entropie rynkową w czasie, należy zauważyć że próba konstrukcji przestrzeni fazowej i interpretacja okresów kryzysu oraz bańek jako różnych faz, podobnie jak w artykule [2], nie zakończyła się sukcesem. Wynika to prawdopodbnie z tego że elemnty wybranego rynku, czyli w tym przypadku etf-y reprezentujące różne giełdy, są z definicji znacznie mniej powiązane niż spółki na tej samej giełdzie. Spółek na giełdzie, jest również znacznie więcej co znacząco wpływa na jakość wyników.

Literatura

[1] Wikipedia *twierdzenie Perrona-Forbeniusa*

[2] Anirban Chakraborti, Hrishidev, Kiran Sharma and Hirdesh K. Pharasi *Phase separation and scaling in correlation structures of financial markets*
link: https://arxiv.org/abs/1910.06242

[3] Investopedia *ETFs*